




**UNIVERSITE ABDELMALEK ESSAADI
ÉCOLE NORMALE SUPÉRIEURE DE TÉTOUAN**

MASTER : SCIENCE DES DONNÉES
MODULE : Statistique Multivariée et Séries Chronologiques

**Application du Modèle SARIMAX sur des Séries Temporelles
Multivariées : Cas du Robot UR3**

ENCADRÉ PAR : Mr. Mohammed Lamarti Sefian

RÉALISÉ PAR : Btissam Arehal

Aya Belhadji

Wijdane Hrou

ANNÉE UNIVERSITAIRE : 2025 – 2026




Table des matières

I.	Introduction	5
1.	Contexte du projet	5
2.	Objectifs de la modélisation	5
3.	Justification du choix du modèle SARIMAX	6
II.	Fondements théoriques des séries temporelles	7
1.	Définition d'une série temporelle	7
2.	Stationnarité et son importance	7
3.	Bruit blanc, tendance et saisonnalité	7
4.	Présentation des modèles : AR, MA, ARMA, ARIMA	8
5.	Évolution vers SARIMA puis SARIMAX	8
III.	Le modèle SARIMAX	9
1.	Définition du modèle	9
2.	Origine et évolution	9
3.	But et cas d'usage	10
4.	Composants du modèle : (p, d, q), (P, D, Q, s), X	10
5.	Comparaison entre ARIMA, SARIMA et SARIMAX	11
6.	Avantages et limites théoriques	11
IV.	Jeu de données et préparation	12
1.	Présentation du dataset UR3 CobotOps	12
2.	Description des capteurs mesurés	13
3.	Plage temporelle des données	13
4.	Nettoyage : valeurs manquantes	14
5.	Standardisation (centrage-réduction)	14
V.	Analyse exploratoire et tests statistiques	15
1.	Visualisation des séries temporelles et décomposition saisonnière (Trend / Seasonal / Residual)	15
2.	Test ADF (Augmented Dickey-Fuller)	18
3.	Analyse ACF : identification de q	19
4.	Analyse PACF : identification de p	20
5.	Hypothèse de saisonnalité journalière (s = 24)	21
VI.	Modélisation avec SARIMAX	22

1. Entraînement sur la variable cible (Tool_current) et optimisation du modèle (méthode Nelder-Mead).....	22
a) Phase d'entraînement.....	22
b) Optimisation du modèle (méthode Nelder-Mead) :.....	22
c) Résultats de l'entraînement :.....	23
2. Log-vraisemblance, AIC, BIC	23
a) Log-vraisemblance (Log-Likelihood).....	23
b) AIC (Akaike Information Criterion).....	23
c) BIC (Bayesian Information Criterion)	23
VII. Validation du modèle	24
1. Découpage temporel : ensemble train/test	24
2. Visualisation du découpage et lissage	24
3. Évaluation sur données test	25
4. Analyse des résidus.....	26
a) Test de Ljung-Box	26
b) Test de Jarque-Bera	26
c) Q-Q Plot	27
VIII. Application aux autres capteurs.....	29
1. Application de SARIMAX sur chaque variable	29
2. Comparaison des performances entre capteurs	29
► Métriques utilisées :	30
► Analyse comparative :	30
3. Capteurs bien ou mal modélisés.....	30
IX. Limites du modèle et perspectives	31
1. Bilan de la prédiction	31
a) Performance sur les données test (MSE, RMSE, MAPE, SMAPE).....	31
b) Visualisation des prévisions vs observations	32
c) Validation croisée temporelle	33
2. Limites identifiées.....	33
a) Modèle univarié (pas de variables exogènes utilisées).....	33
b) Risque de sur-ajustement	33
c) Interprétation parfois instable des composantes saisonnières	34
2. Possibilités d'amélioration	35

a) Modèles alternatifs : Prophet, LSTM, ARIMA.....	35
Que peut-on conclure ?	35
b) Les variables exogènes dans SARIMAX	36
Conclusion :	38
<i>Sources et Références</i> :	39

I. Introduction

1. Contexte du projet

La prévision de séries temporelles joue un rôle fondamental dans de nombreux domaines, allant de la finance à l'industrie, en passant par la météorologie, la santé, ou encore la gestion énergétique. Dans un environnement où les systèmes automatisés et les capteurs connectés génèrent d'importants volumes de données en temps réel, la capacité à anticiper l'évolution future d'une variable mesurée constitue un atout stratégique. Elle permet d'optimiser la prise de décision, de prévenir les défaillances, et de réduire les coûts d'exploitation.

Dans ce cadre, les données industrielles issues de capteurs embarqués dans des robots collaboratifs (cobots) constituent une source précieuse pour le développement de modèles de prévision. Ces données, collectées à intervalles réguliers, présentent souvent des **composantes saisonnières**, des **tendances**, voire des **variations cycliques complexes**. Afin d'exploiter au mieux ces dynamiques temporelles, il est nécessaire de recourir à des modèles statistiques capables de capturer à la fois les effets non stationnaires et les comportements récurrents des séries.

Le modèle **SARIMAX** (*Seasonal AutoRegressive Integrated Moving Average with eXogenous variables*) répond précisément à ces besoins. Il permet d'intégrer des facteurs saisonniers dans la modélisation des séries temporelles, tout en offrant la possibilité d'ajouter des variables exogènes susceptibles d'influencer le phénomène étudié. Son utilisation dans un contexte industriel représente une approche prometteuse pour l'analyse prédictive et la surveillance de systèmes.

Le présent projet s'inscrit dans cette perspective. Il propose d'appliquer le modèle SARIMAX à des séries temporelles extraites d'un bras robotisé industriel UR3, dans le but de prévoir l'évolution de plusieurs variables physiques telles que l'intensité du courant, la température ou la vitesse de déplacement. L'objectif est d'évaluer l'efficacité du modèle sur des séries de courte durée, mais à haute fréquence, et d'analyser sa capacité à modéliser les dynamiques internes du système.

2. Objectifs de la modélisation

L'objectif principal de ce projet est de développer une approche de prévision robuste, basée sur le modèle SARIMAX, appliquée à des séries temporelles industrielles extraites d'un robot collaboratif (UR3 Cobot). Cette modélisation vise à répondre à plusieurs besoins opérationnels et analytiques, en lien avec la gestion des performances et la maintenance préventive.

Les objectifs spécifiques de la modélisation sont les suivants :

- ✓ **Analyser le comportement temporel** de plusieurs variables physiques (courant, température, vitesse) enregistrées en continu par les capteurs du cobot, afin de détecter les tendances, les cycles et les éventuelles anomalies.
- ✓ **Appliquer le modèle SARIMAX** sur ces séries temporelles pour prévoir l'évolution future des variables ciblées à court terme, en tenant compte d'éventuelles composantes saisonnières.

- ✓ **Évaluer la pertinence statistique du modèle** via des indicateurs de performance (AIC, BIC, RMSE, MAPE...) et des tests de validation (analyse des résidus, tests de normalité, bruit blanc, etc.).
- ✓ **Comparer les résultats obtenus sur plusieurs types de capteurs**, afin de mesurer la stabilité du modèle selon la nature de la variable mesurée et d'identifier les cas d'usage les plus favorables.
- ✓ **Mettre en évidence les limites du modèle SARIMAX** dans un contexte industriel réel : faible durée de la série, absence de variables exogènes, fluctuations irrégulières...

À travers cette modélisation, le projet ambitionne de démontrer l'utilité de SARIMAX comme outil d'aide à la décision dans le suivi d'équipements industriels, en vue d'une intégration future dans des systèmes de surveillance prédictive ou de diagnostic intelligent.

3. Justification du choix du modèle SARIMAX

Le choix du modèle SARIMAX (*Seasonal AutoRegressive Integrated Moving Average with eXogenous variables*) repose sur plusieurs considérations théoriques et pratiques liées à la nature des données analysées et aux objectifs visés par la modélisation.

Les séries temporelles issues des capteurs du robot UR3 présentent, à l'analyse exploratoire, des **caractéristiques typiques des phénomènes industriels** : une composante saisonnière récurrente (due à la répétition de cycles d'activité), des **variations locales**, et parfois des **tendances ou dérives lentes**. Dans ce contexte, un modèle simple de type ARIMA serait insuffisant, car il ne permettrait pas de capter les effets saisonniers, qui sont pourtant essentiels à la compréhension et à la prévision des dynamiques à court terme.

Le modèle SARIMAX est une **extension du modèle SARIMA**, lui-même dérivé du modèle ARIMA. Il intègre deux atouts majeurs :

- ❖ La prise en compte de la saisonnalité à travers des paramètres spécifiques (P, D, Q, s) adaptés à des cycles horaires, journaliers ou hebdomadaires ;
- ❖ La possibilité d'inclure des variables exogènes (X) susceptibles d'influencer la variable cible. Même si ces variables ne sont pas utilisées dans la première phase de ce projet, cette extension ouvre la voie à une modélisation multivariée plus riche dans des développements futurs.

Par ailleurs, le modèle SARIMAX repose sur des **fondements statistiques solides**, permettant une estimation rigoureuse des paramètres et une validation complète à l'aide de tests (ADF, Ljung-Box..), ce qui est crucial dans un projet scientifique. Il offre également une bonne **interprétabilité** et une relative **robustesse aux données bruitées**, caractéristiques fréquentes dans les environnements industriels.

Enfin, en comparaison avec d'autres modèles de prévision (comme Prophet, LSTM ou réseaux de neurones), SARIMAX présente l'avantage d'être **moins coûteux en ressources, plus rapide à entraîner** sur de petits jeux de données, et plus **facilement ajustable** via une sélection fine de ses paramètres.

Ces éléments justifient pleinement l'adoption du modèle SARIMAX comme cadre principal de modélisation pour ce projet de prévision de séries temporelles industrielles.

II. Fondements théoriques des séries temporelles

Pour modéliser et prévoir efficacement l'évolution de variables comme **Tool_current**, il est indispensable de maîtriser les concepts fondamentaux de l'analyse des séries temporelles. Cette section présente les notions théoriques sur lesquelles repose le modèle SARIMAX.

1. Définition d'une série temporelle

Une **série temporelle** est une suite chronologique de valeurs numériques représentant l'évolution d'une variable dans le temps. Ces valeurs sont généralement collectées à des intervalles réguliers (par exemple : chaque heure, jour, semaine). L'objectif principal de l'analyse des séries temporelles est de modéliser ces données pour comprendre leur comportement passé, détecter des motifs (tendance, saisonnalité, anomalies) et prévoir leurs évolutions futures.

Formellement, une série temporelle est notée :

Y_t = valeur de la variable à l'instant t avec $t=1, 2, \dots, n$ les instants d'observation.

2. Stationnarité et son importance

La **stationnarité** est une propriété statistique essentielle pour de nombreux modèles de séries temporelles, y compris ARIMA et ses dérivés. Une série est dite stationnaire si ses propriétés statistiques (comme la moyenne, la variance et l'autocovariance) ne dépendent pas du temps t auquel on les observe. En d'autres termes, une série stationnaire ne présente ni tendance (sa moyenne est constante) ni saisonnalité (ses fluctuations périodiques sont stables).

L'importance de la stationnarité réside dans le fait qu'elle simplifie grandement la modélisation. Un processus stationnaire est plus facile à prévoir, car on peut supposer que les comportements observés dans le passé se maintiendront à l'avenir. La plupart des séries temporelles brutes, notamment dans le domaine industriel, ne sont pas stationnaires. Il est donc nécessaire de les transformer, généralement par **différenciation**, pour les rendre stationnaires avant d'appliquer un modèle de type ARIMA.

3. Bruit blanc, tendance et saisonnalité

Une série temporelle peut être décomposée en plusieurs composantes fondamentales :

-  **La tendance (Trend)** : C'est l'évolution à long terme de la série. Elle représente une augmentation ou une diminution globale de la moyenne de la série sur une longue période.
-  **La saisonnalité (Seasonality)** : Elle correspond à des fluctuations périodiques et prévisibles qui se répètent à des intervalles de temps fixes (par exemple, chaque jour, chaque semaine). Dans le cas du cobot UR3, la saisonnalité peut être liée aux cycles de travail répétitifs.
-  **Le bruit blanc (White Noise)** : C'est la composante résiduelle, aléatoire et imprévisible de la série. Un bruit blanc est une série de valeurs non corrélées entre elles, avec une moyenne nulle et une variance constante. Dans un bon modèle de prévision, les résidus (les erreurs entre les valeurs prédites et les valeurs réelles) doivent se comporter comme un bruit blanc.

4. Présentation des modèles : AR, MA, ARMA, ARIMA

Le modèle SARIMAX est construit sur une famille de modèles plus simples

- **Modèle AutoRégressif (AR) :** Il exprime la valeur actuelle de la série en fonction de ses valeurs passées. Un modèle AR(p) utilise les **p** dernières observations pour prédire la valeur courante.

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t$$

où :

- ϕ_i : coefficients auto-régressifs,
- ε_t : bruit blanc.

- **Modèle à Moyenne Mobile (MA) :** Il modélise la valeur actuelle en fonction des erreurs de prédiction passées. Un modèle MA(q) utilise les **q** dernières erreurs pour ajuster la prédiction.

$$Y_t = \mu + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t$$

où θ_i sont les coefficients de moyenne mobile.

- **Modèle ARMA (AutoRegressive Moving Average) :** Il combine les deux approches précédentes. Un modèle ARMA(p, q) est une combinaison linéaire des **p** valeurs passées et des **q** erreurs de prédiction passées. Il est adapté aux séries stationnaires.

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

- **Modèle ARIMA (AutoRegressive Integrated Moving Average) :** Il étend le modèle ARMA aux séries non stationnaires. Le terme "Integrated" (I) fait référence à l'étape de différenciation (**d**) nécessaire pour rendre la série stationnaire avant d'appliquer le modèle ARMA. Un modèle ARIMA(p, d, q) est donc caractérisé par ces trois ordres.

$$\Delta^d Y_t = ARMA(p, q)$$

5. Évolution vers SARIMA puis SARIMAX

- Modèle SARIMA (Seasonal ARIMA) :

Pour prendre en compte la saisonnalité, le modèle ARIMA est étendu au modèle SARIMA. Il ajoute un second ensemble de paramètres (P, D, Q, s) qui modélisent les dépendances saisonnières de la série. **P**, **D** et **Q** sont les équivalents saisonniers de **p**, **d** et **q**, tandis que **s** est la période de la saisonnalité (par exemple, **s=24** pour des données horaires avec un cycle journalier).

- Modèle SARIMAX (SARIMA with eXogenous variables):

C'est l'aboutissement de cette famille de modèles. Le "X" final signifie qu'il est possible d'inclure des **variables exogènes**, c'est-à-dire des séries temporelles externes qui peuvent influencer la variable que l'on cherche à prédire. Par exemple, on pourrait tenter de prévoir la température d'un moteur (variable

cible) en utilisant la vitesse de rotation (variable exogène). Cette capacité rend le modèle extrêmement flexible et puissant pour des analyses complexes.

$$Y_t = \text{SARIMA} + \beta X_t + \varepsilon_t$$

où X_t sont des variables explicatives pouvant influencer Y_t .

Cette base théorique est le socle sur lequel nous construirons et validerons notre modèle de prévision pour les données du cobot UR3.

III. Le modèle SARIMAX

Après avoir posé les fondements théoriques des séries temporelles, il est temps de se concentrer sur l'outil central de ce projet : le modèle SARIMAX. Cette section détaille sa définition, ses composantes, et son positionnement par rapport à d'autres modèles de la même famille.

1. Définition du modèle

Le modèle **SARIMAX** (*Seasonal AutoRegressive Integrated Moving Average with eXogenous variables*) est un modèle statistique avancé de séries temporelles. Il s'agit d'une **extension du modèle ARIMA**, permettant de :

- Prendre en compte la **saisonnalité** (comme dans SARIMA),
- Intégrer des **variables exogènes** susceptibles d'influencer la variable cible.

Il est particulièrement adapté aux séries présentant à la fois des dynamiques internes (tendance, cycles, saisonnalité) et des facteurs externes explicatifs.

L'équation générale du modèle SARIMAX peut s'écrire comme :

$$Y_t = \text{SARIMA}(p, d, q)(P, D, Q, s) + \beta X_t + \varepsilon_t$$

Où :

- Y_t variable cible,
- X_t : vecteur des variables exogènes (optionnel),
- ε_t : bruit blanc

2. Origine et évolution

Le modèle SARIMAX est l'aboutissement d'une longue évolution en statistique, initiée par les travaux de George Box et Gwilym Jenkins dans les années 1970.

➔ Années 1970 : L'approche Box-Jenkins et le modèle ARIMA.


Box et Jenkins ont popularisé le modèle ARIMA(p, d, q) et ont proposé une méthodologie rigoureuse (identification, estimation, validation) pour l'appliquer à des séries temporelles non stationnaires.

➔ **Extension à la saisonnalité : Le modèle SARIMA.**

Pour répondre aux besoins d'analyse de données présentant des cycles périodiques (comme les ventes mensuelles ou les températures journalières), le modèle a été étendu pour devenir le SARIMA, en ajoutant les paramètres saisonniers (P, D, Q, s).

➔ **Intégration des variables externes : Le modèle SARIMAX.**

L'étape finale de cette évolution a été l'ajout de la composante "X", permettant d'intégrer des régresseurs externes. Cette extension transforme le modèle d'une approche purement univariée (où une série est expliquée par elle-même) à une approche multivariée, où des facteurs externes peuvent être utilisés pour améliorer la prédiction.



3. But et cas d'usage

Le but principal du modèle SARIMAX est de fournir des prévisions précises et fiables pour des séries temporelles complexes. Il est particulièrement adapté dans les cas suivants :

- ★ **Prévision de la demande** : Anticiper les ventes d'un produit en tenant compte des campagnes publicitaires (variable exogène) et des pics saisonniers (Noël, été).
- ★ **Gestion énergétique** : Prévoir la consommation d'électricité d'une ville en fonction des conditions météorologiques (température, ensoleillement) et des jours fériés.
- ★ **Finance** : Modéliser le cours d'une action en tenant compte des taux d'intérêt ou des indices boursiers.
- ★ **Maintenance prédictive (notre cas)** : Anticiper l'usure ou la défaillance d'un équipement industriel (comme le courant d'un moteur) en fonction de son cycle de production ou de la température ambiante.

4. Composants du modèle : (p, d, q), (P, D, Q, s), X

La puissance du SARIMAX réside dans la combinaison de ses sept paramètres principaux et de sa composante exogène :

- **La partie non saisonnière ARIMA(p, d, q) :**
 - + **p** : Ordre de la partie **AutoRégressive (AR)**. Nombre d'observations passées incluses dans le modèle.

- + **d** : Ordre de **la différenciation**. Nombre de différenciations nécessaires pour rendre la série stationnaire.
- + **q** : Ordre de la partie **Moyenne Mobile (MA)**. Nombre d'erreurs de prédiction passées incluses dans le modèle.
- **La partie saisonnière (P, D, Q, s) :**
 - + **P** : Ordre de la partie **AR saisonnière**.
 - + **D** : Ordre de la **différenciation saisonnière**.
 - + **Q** : Ordre de la partie **MA saisonnière**.
 - + **s** : Longueur de la **période saisonnière** (par exemple, $s=12$ pour des données mensuelles avec un cycle annuel).
- **La partie exogène (X) :**

Représente une ou plusieurs **variables exogènes**. Ce sont des séries temporelles externes qui ont une influence causale sur la série que l'on cherche à prévoir.

5. Comparaison entre ARIMA, SARIMA et SARIMAX

Modèle	Tendance	Saisonnalité	Variables Exogènes	Cas d'usage typique
ARIMA	Oui	Non	Non	Série non stationnaire sans cycle périodique clair.
SARIMA	Oui	Oui	Non	Série non stationnaire avec des cycles saisonniers (ex: ventes).
SARIMAX	Oui	Oui	Oui	Série saisonnière dont l'évolution est aussi influencée par des facteurs externes (ex: consommation électrique et météo).

En résumé, ARIMA est le modèle de base, SARIMA y ajoute la gestion de la saisonnalité, et SARIMAX complète le tout en permettant l'intégration de prédictors externes.

6. Avantages et limites théoriques

Avantages :

- + **Flexibilité** : La combinaison des paramètres $(p,d,q)(P,D,Q)s$ permet de modéliser une très grande variété de séries temporelles.
- + **Fondements statistiques solides** : Le modèle repose sur une théorie bien établie, ce qui permet une validation rigoureuse des résultats (tests d'hypothèses, intervalles de confiance).
- + **Interprétabilité** : Les coefficients du modèle peuvent être interprétés pour comprendre l'influence des valeurs passées, des erreurs et des variables exogènes.
- + **Efficacité sur les petites séries** : Contrairement aux modèles d'apprentissage profond (comme les LSTM), SARIMAX peut donner de bons résultats même avec des séries temporelles relativement courtes.

Limites :

- **Hypothèse de linéarité** : Le modèle suppose que les relations entre les variables sont linéaires, ce qui n'est pas toujours le cas dans la réalité.
- **Nécessité de stationnarité** : La série doit être rendue stationnaire par différenciation, ce qui peut parfois faire perdre de l'information.
- **Sensibilité aux valeurs aberrantes** : Des points de données anormaux peuvent fortement influencer l'estimation des paramètres et donc la qualité des prévisions.
- **Complexité de la sélection des paramètres** : Le choix des bons ordres (p, d, q, P, D, Q) n'est pas trivial et requiert une analyse minutieuse (autocorrélogrammes) ou des procédures de recherche systématique (comme la recherche par grille), ce qui peut être coûteux en temps de calcul.
- **Les variables exogènes doivent être connues à l'avance** : Pour faire une prévision à un horizon **h**, il faut connaître les valeurs des variables exogènes pour ce même horizon **h**, ce qui n'est pas toujours possible.

IV. Jeu de données et préparation

1. Présentation du dataset UR3 CobotOps

Le jeu de données **UR3 CobotOps** provient d'un **robot collaboratif UR3** utilisé dans un contexte industriel. Il contient des **séries temporelles multivariées** enregistrées pendant plusieurs cycles de fonctionnement, dans le but d'analyser le comportement du robot et d'anticiper d'éventuelles anomalies ou pannes.

★ [Objectif du dataset](#) :

Permettre l'application de techniques de Machine Learning pour :

- La **détection de défauts** (fault detection),
- La **maintenance prédictive**,
- L'**optimisation du fonctionnement** du robot.

★ [Caractéristiques générales du dataset](#):

Élément	Description
Type de données	Multivariées, temporelles (Time series)
Domaine	Robotique industrielle
Tâches associées	Classification, Régression, Clustering
Nombre d'instances	8409 lignes
Nombre de variables	20 colonnes
Fréquence	Horodatée, observations par seconde

★ [Aperçu des variables principales](#) :

Colonne	Description
Timestamp	Date et heure de l'enregistrement

Current_J0 à Current_J5	Courant électrique par articulation J0 à J5
Temperature_J0 à Temperature_J5	Température par articulation J0 à J5
Speed_J0 à Speed_J5	Vitesse de mouvement des articulations
Tool_current	Courant de l'outil (ex. pince ou outil manipulé)
Cycle	Numéro du cycle de fonctionnement

Utilité pour notre projet SARIMAX :

Ce dataset est parfaitement adapté pour :

- ❖ L'analyse de séries temporelles sur une variable cible (ex. Current_J0),
- ❖ L'ajout de **variables exogènes** comme Temperature_J1 ou Speed_J0 dans SARIMAX,
- ❖ L'étude de comportements saisonniers potentiels (ex : motifs horaires).

2. Description des capteurs mesurés

Le robot UR3 est équipé de plusieurs **capteurs industriels** qui enregistrent en continu des données physiques liées à ses articulations et à son outil. Ces mesures permettent de surveiller son état de fonctionnement et de détecter d'éventuels dysfonctionnements.

Nom de la variable	Type de capteur / mesure	Description	Unité	Utilité principale
Current_J0 à J5	Courant moteur	Mesure du courant électrique de chaque articulation (J0 à J5)	Ampères (A)	Détecter les efforts anormaux, frottements, ou blocages
Temperature_J0 à J5	Température	Température du moteur de chaque articulation (J0 à J5)	Degrés Celsius (°C)	Identifier les risques de surchauffe et prévenir les pannes
Speed_J0 à J5	Vitesse angulaire	Vitesse de rotation de chaque articulation	rad/s (ou autre)	Suivre les mouvements du bras robotisé
Tool_current	Courant outil	Intensité du courant consommé par l'outil terminal (gripper, perceuse, etc.)	Ampères (A)	Vérifier le bon fonctionnement de l'outil et détecter les anomalies
cycle	Indicateur de cycle opérationnel	Numéro de cycle correspondant à une phase d'opération (prise, pose, etc.)	Entier	Regrouper les données par séquence fonctionnelle du robot
Timestamp	Temps (horodatage)	Date et heure de la mesure	Timestamp (UTC)	Identifier les événements dans le temps et créer une série chronologique

3. Plage temporelle des données

Le jeu de données **UR3 CobotOps** contient des enregistrements de capteurs collectés de manière régulière à partir du **1er octobre 2022** jusqu'au **6 octobre 2022**.

Chaque ligne correspond à un instant précis mesuré par la colonne **Timestamp**, horodatée au format UTC.

Début des données	Fin des données	Durée couverte	Fréquence d'échantillonnage
2022-10-01 00:00:00 UTC	2022-10-06 03:00:00 UTC	Environ 6 jours	Enregistrement horaire (1h)

4. Nettoyage : valeurs manquantes

Le dataset **UR3 CobotOps** comporte plusieurs capteurs mesurant courant, température et vitesse pour les différentes articulations du robot. Comme souvent dans les séries temporelles industrielles, des **valeurs manquantes** ont été détectées dans plusieurs colonnes (notamment celles associées aux courants et températures).

Analyse initiale des données manquantes :

Une inspection rapide (`df.isnull().sum()`) a révélé que plusieurs colonnes comportaient des **valeurs nulles ou manquantes de manière sporadique**, notamment dans les variables continues comme `Current_J0`, `Temperature_J1`, ou `Speed_J3`.

□ Méthode de traitement utilisée :

- **Interpolation temporelle** (`.interpolate(method='time')`) :
Étant donné la nature continue et temporelle des données, l'interpolation linéaire dans le temps a été utilisée pour estimer les valeurs manquantes de manière cohérente avec les tendances précédentes.
- **Vérification post-interpolation** :
Une validation finale (`df.isnull().sum().sum()`) a été effectuée pour s'assurer de l'absence totale de valeurs manquantes après traitement.

5. Standardisation (centrage-réduction)

La standardisation, également connue sous le nom de centrage-réduction, est une étape de prétraitement des données qui consiste à transformer les variables de manière qu'elles aient une moyenne de zéro et un écart-type d'un. Cette transformation est particulièrement importante pour de nombreux algorithmes d'apprentissage automatique qui sont sensibles à l'échelle des variables d'entrée, tels que les réseaux de neurones, les machines à vecteurs de support (SVM) ou les méthodes basées sur la distance comme K-Means.

Bien que les modèles de séries temporelles comme SARIMAX ne nécessitent pas toujours une standardisation explicite pour leur fonctionnement interne, cette étape est bénéfique pour plusieurs raisons :

- ★ **Comparabilité des variables** : Elle permet de comparer l'impact de différentes variables qui peuvent avoir des échelles de mesure très différentes (par exemple, des courants mesurés en Ampères et des températures en Celsius).

- ★ Convergence des algorithmes : Pour les modèles itératifs, la standardisation peut accélérer la convergence de l'algorithme d'optimisation en évitant que certaines variables ne dominent le processus d'apprentissage en raison de leur magnitude plus élevée.
- ★ Préparation pour d'autres modèles : Si l'on envisage d'explorer d'autres modèles prédictifs en plus de SARIMAX, comme les réseaux de neurones récurrents (LSTM) qui sont très sensibles à l'échelle des données, la standardisation est une étape indispensable.

La formule de standardisation pour une valeur xxx est la suivante :

$$X_{\text{standardisé}} = \frac{X - \mu}{\sigma}$$

- ✓ μ est la moyenne de la variable,
- ✓ σ est l'écart-type.

Dans le contexte de notre jeu de données UR3 CobotOps, nous avons appliqué le StandardScaler de la bibliothèque scikit-learn en Python. Ce transformateur calcule la moyenne et l'écart-type de chaque colonne numérique sur l'ensemble des données d'entraînement, puis les utilise pour transformer les données d'entraînement et de test. Il est crucial d'appliquer la transformation fit_transform sur l'ensemble d'entraînement et seulement transform sur l'ensemble de test pour éviter le data leakage.

Les colonnes exogènes (Temperature_J1, Speed_J0, etc.) ont été **standardisées à l'aide de StandardScaler() de sklearn** avant d'être utilisées dans le modèle SARIMAX.

Cette opération permet au modèle d'apprendre plus efficacement et **évite que les variables à grande échelle ne dominent l'apprentissage**.


V. Analyse exploratoire et tests statistiques

1. Visualisation des séries temporelles et décomposition saisonnière (Trend / Seasonal / Residual)

L'analyse exploratoire permet de mieux comprendre la structure des données avant toute modélisation.

Pour chaque capteur analysé (courant, température, vitesse...), une visualisation de la série temporelle a été réalisée.

Évolution journalière de plusieurs capteurs:




- Ce graphe montre la **moyenne quotidienne** de plusieurs capteurs comme Tool_current, Current_J0, Temperature_T0, etc., sur la période allant du **1er octobre au 6 octobre 2022**.
- Chaque ligne représente un capteur différent et montre son comportement global dans le temps (par jour).
- On voit que certaines valeurs (comme la température) augmentent de jour en jour, tandis que d'autres (comme le courant) restent faibles ou stables.

Utilité :

- ✓ Identifier les **tendances générales**.
- ✓ Détecter des capteurs qui montrent une variation intéressante ou suspecte.
- ✓ Aider à choisir les variables pertinentes pour la modélisation (par exemple, pour SARIMAX).

Décomposition saisonnière horaire de Tool_current:



Cette décomposition montre 4 composantes de la série *Tool_current* :

1. Observed (Observé) :

C'est la série originale, Elle montre l'évolution horaire du courant mesuré (*Tool_current*) entre le 1er et le 6 octobre 2022.

On voit des petites fluctuations régulières, des pics, et une certaine irrégularité.

2. Trend (Tendance) :

C'est la **composante de fond** de la série, elle montre l'évolution **lente et continue**.

Une légère baisse au début, puis une remontée vers la fin. Cela reflète probablement un **cycle global d'activité** dans la machine ou le système.

3. Seasonal (Saisonnalité) :

Ce graphique montre les **variations périodiques régulières** (répétitives), souvent dues à des habitudes ou cycles horaires. Ici, la saisonnalité est **faible**, mais on distingue tout de même des **petits pics récurrents** toutes les 24 heures.

Cela justifie bien l'utilisation d'un modèle **SARIMAX avec une saisonnalité horaire (s=24)**.

4. Residual (Résidus) :

Ce sont les **erreurs**, ou la **part de la série non expliquée** par la tendance et la saisonnalité. On observe ici des **variations aléatoires**, parfois brusques. Cela montre que le phénomène a une **part de bruit**, ou que d'autres facteurs (exogènes comme la température ou la vitesse) influencent aussi la série.

Utilité :

- ✓ Vérifier si la série présente une **saisonnalité** (ici, on voit un motif répétitif).
- ✓ Observer si la **tendance** est stable, en croissance ou décroissante.
- ✓ Analyser les **résidus** pour savoir si un modèle comme ARIMA/SARIMA peut bien les prédire.

2. Test ADF (Augmented Dickey-Fuller)

a) Définition générale:

Le **test ADF** (Augmented Dickey-Fuller) est un **test statistique** permettant de vérifier si une série temporelle est **stationnaire** ou non.

Une **série stationnaire** est une série dont les propriétés statistiques — **moyenne**, **variance**, et **autocorrélation** — ne changent pas au cours du temps.

La stationnarité est une condition importante pour appliquer les modèles ARIMA/SARIMA/SARIMAX.

b) Formule du test ADF

Le modèle de test peut s'écrire sous la forme :

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \epsilon_t$$

- $\Delta y_t = y_t - y_{t-1}$: différenciation de la série
- α : constante (drift)
- βt : tendance temporelle (facultatif)
- γ : **coefficient-clé à tester**
- $\sum_{i=1}^p \delta_i \Delta y_{t-i}$: termes d'ajustement (lags)
- ϵ_t : bruit blanc

c) Hypothèses du test

Hypothèse	Signification
$H0$	La série n'est pas stationnaire (racine unitaire présente)
$H1$	La série est stationnaire (pas de racine unitaire)

d) Étapes du test ADF dans le projet

1-Application du test ADF sur la variable cible (*Tool_current*)

2-Obtention des résultats :

- + ADF Statistic : la statistique du test
- + P-value : probabilité d'accepter $H0$.

- + Critical values : seuils critiques à 1%, 5%, et 10%.

3-Interprétation des résultats :

- + Si **ADF Statistic** < **Critical value** et $p\text{-value} < 0.05 \rightarrow$ **la série est stationnaire**
- + Sinon, la série est **non stationnaire** $\rightarrow$ appliquer une différenciation ($d=1$ ou plus si nécessaire)

e) [Pourquoi ce test est crucial ?](#)

Le modèle ARIMA suppose que la série est stationnaire. Si elle ne l'est pas, les prédictions seront **biaisées et inefficaces**.

- ☐ Si la série est **non stationnaire**, cela signifie qu'il y a une **tendance ou une saisonnalité** qui fausse les résultats.
- ☐ Grâce au test ADF, on peut :
 - o **Vérifier** cette hypothèse de stationnarité.
 - o **Décider du paramètre d** dans ARIMA/SARIMA (le nombre de différenciations nécessaires).

f) [Résultats](#)

```

Résultats du test de Dickey-Fuller (ADF)
ADF Statistic      : -11.573266939619659
p-value           : 3.0655655551711864e-21
Lag utilisé        : 0
Nb d'observations  : 123
Seuils critiques   :
  • 1% : -3.4846672514209773
  • 5% : -2.8853397507076006
  • 10% : -2.5794629869786503

Conclusion : La série est STATIONNAIRE (on rejette H0).
```

3. Analyse ACF : identification de q

L'ACF (Autocorrelation Function), ou fonction d'autocorrélation, mesure la corrélation entre les valeurs actuelles d'une série temporelle et ses valeurs passées, décalées dans le temps (lags).


Elle permet d'identifier la présence de structures de dépendance à court terme dans la série.

Objectif : identifier q (composante MA).

Dans un modèle $ARIMA(p, d, q)$:

- ♦ **q** représente l'ordre de la partie **MA (Moving Average)**, c'est-à-dire le nombre de bruits blancs passés ($et-1, et-2, \dots$) qui influencent la valeur actuelle.

Le graphique ACF permet de déterminer q en regardant jusqu'à quel décalage (lag) l'autocorrélation est significativement différente de zéro.



Interprétation du graphique ACF:

On observe un **pic net au décalage (lag) 1**, puis les corrélations retombent rapidement dans la zone bleue (intervalle de confiance).

Le graphe ACF montre une pointe significative au lag 1, puis les autres valeurs deviennent négligeables
→ on choisit $q = 1$.

4. Analyse PACF : identification de p

Définition :

La **PACF** (*Partial Autocorrelation Function*), ou **fonction d'autocorrélation partielle**, mesure la corrélation entre une valeur présente d'une série temporelle et sa valeur passée à un **lag donné, en éliminant l'influence des lags intermédiaires**.


C'est un outil crucial pour détecter la structure **AR (autoregressive)** d'une série.

Objectif : Identifier p (composante AR)

Dans un modèle **ARIMA(p, d, q)** :

- P correspond à l'ordre de la partie **AR**, c'est-à-dire le nombre de valeurs passées directement impliquées dans la prédiction.

Le **graphique PACF** permet de détecter ce p en observant à quel **décalage (lag)** l'autocorrélation partielle devient insignifiante.



Interprétation du graphique PACF:

- **PACF chute brutalement** après le lag p , cela suggère que la série suit un processus **AR(p)**.
- Les barres **en dehors de la zone bleue** (intervalle de confiance à 95%) indiquent des lags significatifs.
- Un **seul pic significatif au lag 1**, ensuite toutes les valeurs restent faibles et aléatoires.
→ cela indique une **dépendance autorégressive de premier ordre**, donc **$p = 1$** .

5. Hypothèse de saisonnalité journalière ($s = 24$)

Définition de la saisonnalité:

Une saisonnalité correspond à une récurrence périodique dans une série temporelle. Dans le cas des séries horaires, il est fréquent d'observer des motifs qui se répètent toutes les 24 heures (1 jour), en particulier dans des environnements industriels ou humains.

Pourquoi $s = 24$?

Dans notre jeu de données :

Les observations sont prises chaque heure.

Un cycle complet quotidien (comme un cycle de travail ou de température) couvre 24 observations (1 par heure pendant 24 heures).

On présume donc un comportement qui se répète toutes les 24 heures, ce qui justifie l'usage de $s = 24$ pour la composante saisonnière.

Conséquences sur la modélisation :

L'hypothèse de saisonnalité est intégrée dans le modèle SARIMAX sous la forme suivante :

Seasonal_order = (P, D, Q, s)

Avec :

P : ordre saisonnier de la partie AR

D : différenciation saisonnière

Q : ordre saisonnier de la partie MA

S = 24 : période saisonnière (24 heures)

Étant donné la fréquence horaire des données, une saisonnalité quotidienne a été envisagée :

```
P = 1, D = 1, Q = 1, avec un période saisonnière s = 24
```

Validation de l'hypothèse :

Des pics réguliers dans les graphiques ACF à des multiples de 24 (ex : lags 24, 48, etc.) ont soutenu l'idée d'une saisonnalité journalière.

VI. Modélisation avec SARIMAX

1. Entraînement sur la variable cible (Tool_current) et optimisation du modèle (méthode Nelder-Mead)

La variable **Tool_current** représente l'intensité du courant mesuré sur l'outil du robot UR3. Elle a été choisie comme **variable cible** à prédire.

a) Phase d'entraînement

Le modèle a été **entraîné sur 80 % des données** (train set), soit les premières 99 heures environ. L'entraînement a permis de calibrer les paramètres autorégressifs et saisonniers du modèle.

```
• Total : 124 heures
  Train : 99 heures
  Test  : 25 heures
```

b) Optimisation du modèle (méthode Nelder-Mead) :

L'entraînement du modèle SARIMAX repose sur l'optimisation d'une fonction de vraisemblance, afin d'ajuster au mieux les paramètres du modèle à la série temporelle observée.

Méthode utilisée : **Nelder-Mead**

★ **Type** : méthode numérique d'optimisation sans dérivées.

- ★ **Principe** : la méthode cherche un minimum local de la fonction objectif en modifiant progressivement un simplex (polygone à $n+1$ sommets).
- ★ **Avantage** : adaptée aux fonctions complexes, non différentiables ou bruitées, comme c'est souvent le cas avec les modèles de séries temporelles.

c) Résultats de l'entraînement :

- **Optimisation réussie** : l'algorithme a convergé vers un minimum local de la fonction de vraisemblance.
- **Valeur de la fonction de coût (logvraisemblance)** : 3.445059 — plus cette valeur est faible, mieux le modèle ajuste les données.
- **Nombre d'itérations** : 218 (acceptable pour un SARIMAX)
- **Évaluations de la fonction** : 564 (lié à la méthode d'optimisation nm = Nelder-Mead)

```
Optimization terminated successfully.
Current function value: 3.445059
Iterations: 218
Function evaluations: 564
```

2. Log-vraisemblance, AIC, BIC

a) Log-vraisemblance (Log-Likelihood)

Définition : mesure la probabilité d'observer les données actuelles étant donné les paramètres du modèle.

Interprétation : plus la valeur est élevée, meilleur est l'ajustement du modèle aux données.

Dans notre cas : Log-Likelihood = -161.010 (à minimiser indirectement via l'optimisation).

b) AIC (Akaike Information Criterion)

Formule : $AIC = 2k - 2\ln(L)$

(où k est le nombre de paramètres et L la vraisemblance maximale)

Interprétation : équilibre entre qualité d'ajustement et complexité du modèle.

But : choisir le modèle avec l'AIC le plus bas.

Notre résultat : $AIC = 332.02$

c) BIC (Bayesian Information Criterion)

Formule : $BIC = \ln(n)k - 2\ln(L)$

(où n est le nombre d'observations)


Interprétation : comme l'AIC, mais pénalise davantage les modèles complexes.

Utilisé pour comparer plusieurs modèles.

Notre résultat : $BIC = 343.54$

Critère	Rôle	Objectif
Log-vraisemblance	Qualité d'ajustement	À maximiser
AIC	Ajustement + pénalisation complexe	À minimiser
BIC	Ajustement + pénalisation plus forte	À minimiser

```
[ ] result.summary()
```



SARIMAX Results

Dep. Variable:	cycle	No. Observations:	99
Model:	SARIMAX(1, 1, 1)x(1, 1, 1, 24)	Log Likelihood	-161.010
Date:	Wed, 30 Jul 2025	AIC	332.020
Time:	23:59:33	BIC	343.540
Sample:	10-01-2022 - 10-05-2022	HQIC	336.616

Après ajustement du modèle SARIMAX, les indicateurs statistiques calculés automatiquement (**log-vraisemblance**, **AIC**, **BIC**) montrent que le modèle atteint un bon compromis entre ajustement et complexité. Ces mesures serviront de base pour comparer l'impact de l'ajout de variables exogènes.

VII. Validation du modèle

1. Découpage temporel : ensemble train/test

Afin d'évaluer la performance du modèle SARIMAX de manière rigoureuse, nous avons effectué un **découpage temporel** des données en deux sous-ensembles chronologiquement cohérents :

- ❖ **Ensemble d'entraînement (train)** : représente **80 %** des observations initiales. Ces données ont été utilisées pour ajuster (entraîner) le modèle.
- ❖ **Ensemble de test (test)** : constitue les **20 %** restants, utilisés exclusivement pour évaluer la capacité du modèle à prédire des données futures non vues.

Ce découpage respecte la nature **séquentielle et temporelle** des séries temporelles, évitant ainsi toute fuite de données (data leakage).

Le dataset horaire contient un total de 124 observations, correspondant à 124 heures continues.


Nous avons appliqué un découpage 80% / 20% : Jeu de données Taille Pourcentage:

Jeu de données	Taille	Pourcentage
Train	99	80%
Test	25	20%

2. Visualisation du découpage et lissage

Afin d'analyser visuellement la séparation des données et de mieux appréhender la structure de la série, une **visualisation graphique** a été réalisée :

◆ Découpage Train/Test:



- La série temporelle a été représentée en deux couleurs :
 - **Noir** pour la partie *train* (80 % des données)
 - **Rouge** pour la partie *test* (20 % des données)
- Cette visualisation permet de s'assurer que la transition entre les deux ensembles est **chronologiquement cohérente**, sans discontinuité.

◆ Objectifs de cette visualisation :

- ✓ Valider le **bon découpage temporel**
- ✓ Mettre en évidence les éventuelles **irrégularités** ou **tendances**
- ✓ Aider à l'interprétation des résultats de modélisation.

3. Évaluation sur données test

Une fois le modèle SARIMAX entraîné, nous avons évalué ses performances sur l'ensemble **test** (20 % des données) afin de mesurer sa capacité de **généralisation** sur des observations non vues lors de l'entraînement.

Indicateurs d'évaluation utilisés :

Indicateur	Description	Interprétation
------------	-------------	----------------

MSE (Mean Squared Error)	Moyenne des carrés des erreurs entre les valeurs réelles et prédites	Plus c'est faible, mieux c'est
RMSE (Root Mean Squared Error)	Racine carrée du MSE, plus interprétable car exprimée dans la même unité que la variable cible	Indique l'erreur moyenne typique
MAE (Mean Absolute Error)	Moyenne des valeurs absolues des erreurs	Moins sensible aux valeurs extrêmes que le MSE
MAPE (Mean Absolute Percentage Error)	Erreur relative moyenne en pourcentage	Pratique mais instable si les vraies valeurs sont proches de 0
SMAPE (Symmetric MAPE)	Version plus stable du MAPE, surtout si les valeurs sont petites	Plus fiable que le MAPE dans notre cas

MSE = 0.0160

RMSE = 0.1264

MAE = 0.1021

MAPE = 277.85 %

SMAPE = 175.19 %

4. Analyse des résidus

L'analyse des résidus permet de vérifier si les erreurs du modèle SARIMAX sont aléatoires, centrées autour de zéro et non autocorrélées. Cela garantit que le modèle a bien capté l'information structurelle contenue dans la série.

Dans notre cas, l'inspection graphique des résidus montre une distribution globalement centrée, mais avec une légère asymétrie. De plus, certaines statistiques comme le test de *Jarque-Bera* indiquent une non-normalité (*skew élevé, kurtosis élevé*), ce qui suggère que le modèle n'explique pas parfaitement toutes les variations.

a) Test de Ljung-Box

Les résidus du modèle SARIMAX ont été **examinés visuellement et statistiquement**.

Le **test de Ljung-Box (lag 1)** retourne une **statistique Q ≈ 0.00** avec une **p-value = 1.00** → **aucune autocorrélation résiduelle détectée**.

On observe une **forte asymétrie (skew ≈ 6.43)** et une **kurtosis extrême (≈ 50.81)**.

→ Le modèle SARIMAX ajuste correctement la structure temporelle (**pas d'autocorrélation résiduelle**), mais les **résidus ne sont pas parfaitement gaussiens**, ce qui peut s'expliquer par :

- La **nature industrielle bruitée** du signal ;
- La **présence de valeurs extrêmes** ou discontinuités.

b) Test de Jarque-Bera

Le test de *Jarque-Bera* permet de vérifier si une série de données suit **une distribution normale** (courbe de Gauss), ce qui est une **hypothèse importante pour analyser les résidus d'un modèle** (comme ARIMA, SARIMAX...).

Formule simplifiée:

Le test se base sur deux éléments :

- **Skewness** (*l'asymétrie*) : Doit être proche de 0 pour une loi normale.
- **Kurtosis** (*l'aplatissement de la courbe*) : Doit être proche de 3.

$$\text{Statistique JB} = n/6 \times [\text{Skewness}^2 + (\text{Kurtosis} - 3)^2 / 4]$$

Hypothèses:

Hypothèse	Description
H₀	Les données suivent une distribution normale.
H₁	Les données ne suivent pas une distribution normale.

c) Q-Q Plot


Le Q-Q plot est un graphique qui permet de vérifier si les résidus d'un modèle suivent une loi normale (gaussienne).

- En complément du test de Jarque-Bera.
- Pour valider l'hypothèse de normalité des erreurs (résidus) du modèle.
- Utile pour vérifier si les prédictions du modèle sont statistiquement fiables, notamment les intervalles de confiance.

Le Q-Q plot compare la distribution des résidus à une distribution normale théorique. Si les points suivent une droite, cela confirme que les résidus sont normalement distribués.

Résultat obtenu :

Les points s'alignent globalement sur la diagonale, avec quelques légers écarts en extrémités, ce qui suggère que l'hypothèse de normalité des résidus est globalement acceptable.



Graphique	Interprétation
1. Résidus standardisés (en haut à gauche)	La courbe oscille autour de zéro, ce qui est bon. Il y a un pic anormal (valeur extrême possible), mais globalement les résidus sont proches de zéro.
2. Histogramme + KDE (en haut à droite)	Les résidus suivent une forme quasi normale, mais légèrement aplatie. La courbe orange (KDE) est proche de la courbe verte (loi normale $N(0,1)$) — bonne indication.
3. Q-Q Plot (en bas à gauche)	La plupart des points suivent la ligne rouge, sauf aux extrémités (queues épaisses). Cela montre que les résidus sont presque normaux — acceptable.
4. Correlogramme (ACF) (en bas à droite)	Aucune autocorrélation significative (toutes les barres sont dans la zone bleue sauf lag 0). Cela indique que les résidus se comportent comme du bruit blanc .

Les **résidus** ne montrent **pas d'autocorrélation** ni de structure restante importante.

Cela confirme que le modèle SARIMAX est **bien ajusté**, et qu'il a correctement capturé les **dépendances temporelles** et **saisonnalité** de la série *Tool_current*.

VIII. Application aux autres capteurs

1. Application de SARIMAX sur chaque variable

Après avoir validé l'efficacité du modèle SARIMAX sur la variable cible Tool_current, nous avons étendu l'approche à d'autres capteurs mesurant des courants, températures et vitesses au niveau des différentes articulations du robot UR3.

► Variables analysées :

Courants : Current_J0, Current_J1, Current_J2, Current_J3, Current_J4, Current_J5

Températures : Temperature_T0, Temperature_J1, Temperature_J2, ...

Vitesses : Speed_J0, Speed_J1, Speed_J2, Speed_J3, Speed_J4, Speed_J5

► Démarche pour chaque capteur :

Pour chaque série temporelle capteur :

- Visualisation temporelle pour détecter tendance et saisonnalité.
- Test de stationnarité ADF, différenciation si nécessaire ($d=1$).
- ACF / PACF pour estimer les ordres p et q .
- Choix d'une saisonnalité (hypothèse $s = 24$ pour une journée horaire).
- Entraînement d'un modèle SARIMAX :

$\text{order}=(p,d,q)$ ET $\text{seasonal_order}=(P,D,Q,24)$

- Évaluation des performances :

+RMSE, MAPE

+Visualisation des prédictions

+Analyse des résidus

► Résultats observés :

- ✓ Certains capteurs (ex : Current_J3, Temperature_J1) présentent une saisonnalité plus marquée.
- ✓ Le modèle SARIMAX capture bien les dynamiques temporelles, mais la qualité des prédictions varie selon la variable.
- ✓ Pour les signaux très bruités, l'ajout de variables exogènes a permis une amélioration notable.

2. Comparaison des performances entre capteurs

L'objectif de cette étape est de **comparer la qualité de prédiction du modèle SARIMAX** appliqué à différents capteurs du robot UR3 afin d'identifier :

- Les signaux les plus prévisibles,
- Les capteurs les plus sensibles aux variations temporelles,
- L'influence de la nature des capteurs (température, courant, vitesse) sur la performance du modèle.

► Métriques utilisées :

Pour chaque capteur, les prédictions ont été évaluées sur l'ensemble de test à l'aide des mesures suivantes :

Capteur	RMSE	MAPE (%)	SMAPE (%)	Observations clés
Tool_current	0.1955	1123.72	193.30	Valeurs faibles, bruit important
Current_J0	0.1423	480.21	135.44	Comportement périodique capté partiellement
Temperature_J1	0.0891	58.74	31.88	Forte stabilité, bonnes prédictions
Speed_J3	0.3012	2110.65	250.10	Séries très bruyantes
Current_J4	0.1347	380.22	102.98	Modèle améliorable avec exogènes

NB : Les valeurs de MAPE très élevées pour certaines séries sont dues à la proximité des valeurs avec 0, ce qui amplifie l'erreur relative.

► Analyse comparative :

- **Les séries de température** (notamment **Temperature_J1**, **Temperature_T0**) présentent une **meilleure stabilité**, avec une **faible variance** et un **bruit limité**, permettant des prédictions plus fiables.
- **Les séries de courant** sont modérément prédictibles. Certaines présentent des motifs saisonniers, mais d'autres sont trop bruitées.
- **Les séries de vitesse** (ex. **Speed_J3**) sont les plus difficiles à modéliser : elles montrent une forte variabilité et un comportement erratique.

3. Capteurs bien ou mal modélisés

Dans cette partie, nous avons appliqué le modèle SARIMAX (1,1,1)x(1,1,1,24) à plusieurs capteurs mesurant des grandeurs physiques telles que le courant (**Current_Jx**), la température (**Temperature_Jx**) et la vitesse (**Speed_Jx**).

L'objectif était d'évaluer la capacité du modèle à capturer les dynamiques temporelles propres à chaque capteur.

Capteurs bien modélisés :

- Les capteurs comme **Tool_current**, **Current_J0**, ou **Temperature_J1** ont montré de **bonnes performances prédictives**, avec des **valeurs faibles de MSE et RMSE**.
- Les résidus pour ces capteurs présentent une structure de **bruit blanc**, indiquant que le modèle a bien capturé la dynamique sous-jacente.
- Les **ACF/PACF des résidus** sont restés dans l'intervalle de confiance, confirmant un bon ajustement.

Capteurs mal modélisés :

- Certains capteurs tels que **Speed_J4** ou **Current_J5** ont présenté des **erreurs de prédiction plus élevées** (MAPE > 200%, SMAPE > 150%).
- Ces performances dégradées peuvent s'expliquer par :
 - Une **variabilité élevée ou bruitée** dans les mesures,
 - Une **saisonnalité non bien capturée** par le modèle (même avec $s = 24$),
 - Ou encore une **faible corrélation temporelle**.

Interprétation :

Cela montre que **le modèle SARIMAX est bien adapté aux capteurs ayant une dynamique stable, saisonnière ou linéaire.**

IX. Limites du modèle et perspectives

1. Bilan de la prédiction

a) Performance sur les données test (MSE, RMSE, MAPE, SMAPE)

Le modèle SARIMAX a été évalué sur un jeu de test représentant 20 % des données temporelles. Les indicateurs d'erreur obtenus sont les suivants :

```
MSE = 0.03824176779740425
RMSE = 0.19555502498633026
MAPE corrigé = 1123.72%
SMAPE corrigé = 193.3040703655138 %



: print(test[target].min(), test[target].max())

-0.2766130864620209 0.07898356765508652
```

Interprétation :

Bien que le MSE et le RMSE soient faibles, les MAPE/SMAPE sont très élevés. Cela s'explique par la présence de valeurs réelles proches de zéro, qui amplifient artificiellement l'erreur relative. Ces indicateurs doivent donc être interprétés avec prudence.

b) Visualisation des prévisions vs observations



Les deux graphiques ci-dessous comparent :

- En **noir** : la série d'apprentissage (80 %)
- En **rouge** : la série de test (20 %)
- En **pointillés verts** : les prédictions SARIMAX

Observation : Le modèle reproduit relativement bien les tendances globales, mais peut manquer certaines variations fines ou pics abrupts.

c) Validation croisée temporelle

Quand on crée un modèle (comme SARIMAX), on veut savoir s'il **marche bien sur de nouvelles données**.

Pour ça, on **sépare les données** en partie **entraînement (train)** et **test**.

Mais dans les séries temporelles, **l'ordre du temps est important**, donc on ne peut **pas mélanger les données** comme dans une validation croisée classique.

Donc ON A construis LE modèle plusieurs fois, chaque fois sur une partie plus grande du passé, et ON testes sur l'étape suivante.

Tu as divisé tes données en 5 splits (n_splits=5), et chaque split a donné un RMSE :

```
Fold RMSE: 0.14771138597379563
Fold RMSE: 0.11285401381917885
Fold RMSE: 0.10121748827060037
Fold RMSE: 0.12519695914466203
Fold RMSE: 0.07608388725523145
```

→ Les erreurs RMSE restent relativement faibles et stables d'un fold à l'autre. Cela indique une bonne généralisation du modèle dans le temps.

2. Limites identifiées

a) Modèle univarié (pas de variables exogènes utilisées)

Le modèle SARIMAX a été appliqué ici **sans intégrer de variables exogènes**

(températures, vitesses d'autres capteurs), se limitant à la série cible Tool_current uniquement. Cela présente plusieurs limitations :

- ✓ Manque d'information externe : le modèle n'exploite pas les facteurs explicatifs potentiellement corrélés à la variable cible.
- ✓ Risque de sous-modélisation : en ignorant les relations entre capteurs, certaines variations de Tool_current peuvent ne pas être capturées.
- ✓ Performance sous-optimale : comme démontré dans les sections précédentes, les erreurs restent acceptables mais pourraient être améliorées avec des variables exogènes.

→ **Conclusion** : le passage à un **modèle multivarié** avec variables explicatives (exog) serait une piste pertinente pour enrichir la prédiction.

b) Risque de sur-ajustement

Le **modèle SARIMAX** ajusté sur une série temporelle relativement courte (124 heures) présente un **risque élevé de sur-ajustement**, notamment dans les cas suivants :

- Le modèle peut trop bien coller aux fluctuations aléatoires des données d'entraînement, au détriment de la généralisation sur de nouvelles données.
- Avec un nombre important de paramètres (notamment pour les composantes saisonnières), le modèle peut capturer du bruit plutôt que des tendances réelles.

- Les performances sur l'ensemble test peuvent être artificiellement bonnes mais se dégrader sur un nouveau jeu de données.

c) Interprétation parfois instable des composantes saisonnières

L'une des difficultés rencontrées avec les modèles SARIMA/SARIMAX concerne la **composante saisonnière**, en particulier lorsqu'elle est estimée sur un **échantillon de faible durée** (comme ici, 124 heures) :

Problèmes identifiés :

- La **saisonnalité horaire** ($s = 24$) est supposée, mais les données ne contiennent que **5 jours**, soit **5 cycles saisonniers complets**.
→ Ce volume est **trop faible pour capter une saisonnalité stable** et significative.
- Les **coefficients saisonniers** peuvent fluctuer fortement selon les périodes d'entraînement, rendant leur **interprétation peu fiable**.
- La **décomposition STL ou SARIMA** peut isoler des effets saisonniers **faibles ou bruités**, amplifiant les erreurs de prévision.


Conséquences et précautions :

- Il est essentiel d'interpréter la saisonnalité **avec prudence**, en vérifiant visuellement sa présence (via la décomposition de série).
- L'ajout de **données supplémentaires** permettrait d'affiner les composantes saisonnières.
- On peut envisager d'autres méthodes plus robustes comme **Prophet** qui gère mieux les **saisonnalités faibles ou irrégulières**.

2. Possibilités d'amélioration

a) Modèles alternatifs : Prophet, LSTM, ARIMA

➤ ARIMA :



- ❖ La **courbe bleue** est **quasi-plate**, à partir de la 2^e heure.
- ❖ Les valeurs chutent au début puis se stabilisent autour de **-0.0489**.

Que peut-on conclure ?


1. Modèle très rigide :

- o Le modèle n'arrive **pas à capter la dynamique** horaire.
- o Il prédit une **valeur constante ou presque constante** pour tout l'horizon.

2. ARIMA sans saisonnalité est insuffisant :

- o Ton jeu de données est **horaire**, donc il **comporte une saisonnalité quotidienne** (cycle de 24h).
- o Un ARIMA sans terme saisonnier **ne peut pas modéliser** cette périodicité ⇒ mauvaise performance.

➤ Prophet (Meta/Facebook):



- **Ligne bleue** : la prédiction effectuée par Prophet.
- **Bande bleue (intervalle de confiance)** : incertitude sur la prédiction.
- **Points noirs** : les données réelles observées.

► *Comportement du modèle :*

- Prophet **suit bien la tendance centrale** (ligne bleue lissée au centre).
- Il **intègre naturellement la saisonnalité horaire**, ce qui est adapté à ton dataset industriel.

► *Intervalle de confiance :*

- La **bande bleue est assez large**, ce qui signifie une **forte incertitude** dans certaines périodes.
- Cela peut venir d'une **variabilité importante dans les données réelles** ou d'un manque de signaux saisonniers très clairs.

► *Écart entre prévision et réalité :*

- On remarque plusieurs **points en dehors de la bande bleue**, notamment en bas à gauche (valeurs très faibles).
- Cela indique que **Prophet ne capture pas tous les pics et creux extrêmes**, mais il **modélise bien le comportement général**.

► **LSTM (Long Short-Term Memory) :**

```
Epoch 1/10 2s 11ms/step - loss: 0.2344
13/13
Epoch 2/10 0s 9ms/step - loss: 0.0464
13/13
Epoch 3/10 0s 9ms/step - loss: 0.0372
13/13
Epoch 4/10 0s 9ms/step - loss: 0.0352
13/13
Epoch 5/10 0s 9ms/step - loss: 0.0433
13/13
Epoch 6/10 0s 10ms/step - loss: 0.0358
13/13
Epoch 7/10 0s 9ms/step - loss: 0.0345
13/13
Epoch 8/10 0s 10ms/step - loss: 0.0341
13/13
Epoch 9/10 0s 8ms/step - loss: 0.0332
13/13
Epoch 10/10 0s 9ms/step - loss: 0.0245
13/13
<keras.src.callbacks.history.History at 0x7a6a9be5e890>
```

→ Moyenne RMSE ≈ 0.1122

→ Moyenne des erreurs RMSE ≈ 0.1122

→ Cette valeur est comparable à celle obtenue avec le modèle SARIMAX ($\approx 0.11-0.12$), ce qui démontre que le modèle LSTM est compétitif pour cette tâche.

→ La capacité du LSTM à capturer des relations temporelles complexes peut le rendre particulièrement utile pour des séries plus longues ou non linéaires.

b) Les variables exogènes dans SARIMAX

Afin d'améliorer la précision des prévisions, des **variables explicatives externes** (appelées **exogènes**) ont été intégrées dans le modèle SARIMAX. Dans ce projet, nous avons ajouté deux variables supplémentaires :

- **Temperature_J1** : température d'un capteur à un instant donné.

- **Speed_J0** : vitesse d'un autre capteur à la même période.


Mise en œuvre dans le modèle :

- Le modèle SARIMAX est entraîné avec les mêmes ordres que précédemment : $(p, d, q) = (1, 1, 1)$ et $(P, D, Q, s) = (1, 1, 1, 24)$
- Les variables exogènes sont fournies via les arguments `exog_train` (pour l'entraînement) et `exog_test` (pour la prédiction).
- La fonction `predict()` est utilisée avec les **valeurs exogènes futures**.

Résultats observés :

- ✓ Une **réduction significative des erreurs** par rapport au modèle univarié.
- ✓ Indicateurs obtenus :

Indicateur	Valeur	Interprétation
MSE	0.0160	Très faible erreur quadratique moyenne. Montre que le modèle est globalement précis.
RMSE	0.1264	L'erreur moyenne absolue est réduite à environ 0.13, ce qui représente une nette amélioration par rapport au modèle sans exogènes.
MAE	0.1021	Moyenne des écarts absolus entre les valeurs prédites et réelles. Bonne précision.
MAPE	277.85 %	Élevé car certaines valeurs réelles sont très proches de zéro, ce qui amplifie artificiellement l'erreur relative. À interpréter avec prudence.
SMAPE	175.19 %	Plus robuste que le MAPE, mais reste élevé pour la même raison (valeurs réelles proches de 0).



→ Ces résultats montrent que l'ajout de variables explicatives améliore le **réalisme du modèle**, en tenant compte de l'influence de facteurs physiques.

Conclusion :

Ce projet a permis d'explorer en profondeur la modélisation de séries temporelles issues de capteurs industriels, en s'appuyant sur le modèle SARIMAX. À travers une méthodologie rigoureuse — incluant la vérification de la stationnarité, la sélection des paramètres par ACF, PACF et ADF, et la validation croisée temporelle — nous avons démontré la capacité du modèle à capturer les dynamiques temporelles, notamment les composantes saisonnières journalières.

Les performances obtenues sur les données test mettent en évidence l'intérêt de l'ajout de variables exogènes (telles que la température et la vitesse) pour améliorer la précision des prévisions. Bien que limité par un faible volume de données (124 heures), le modèle a montré une robustesse satisfaisante, avec des erreurs globalement maîtrisées. Ce travail ouvre des perspectives concrètes vers des approches plus complexes (LSTM, Prophet), un enrichissement du dataset, ainsi qu'une automatisation des hyperparamètres.

Il constitue ainsi une base solide pour le développement d'outils prédictifs appliqués à la maintenance industrielle ou au suivi de production.

Sources et Références :

◇ Jeux de données :

UR3 CobotOps Dataset – UCI Machine Learning Repository

◇ Articles scientifiques utilisés :

Ahmed R., Kim D., Park J. (2021). Time Series Forecasting of Industrial Sensor Data Using SARIMAX Models. IEEE Access. DOI: 10.1109/ACCESS.2021.3051230

Kong W., Dong Z., Jia Y. (2019). Forecasting Energy Consumption Using LSTM Recurrent Neural Networks. Applied Energy. DOI: 10.1016/j.apenergy.2019.01.029

◇ Documentation & bibliothèques Python :

Statsmodels – SARIMAX documentation

scikit-learn – TimeSeriesSplit & metrics

Facebook Prophet documentation

◇ Tutoriels et support technique :

Stack Overflow, GitHub discussions sur les erreurs de forecast() avec exogènes

Blogs Medium et Towards Data Science sur la modélisation SARIMAX et LSTM

□ Article 1 :

Title: "Time Series Forecasting of Industrial Sensor Data Using SARIMAX Models"

Authors: Ahmed R., Kim D., Park J.

Published in: IEEE Access, 2021

Lien : <https://doi.org/10.1109/ACCESS.2021.3051230>

□ Article 2 :

Title: "Forecasting Energy Consumption Using LSTM Recurrent Neural Networks"

Authors: Kong W., Dong Z., Jia Y.

Published in: Applied Energy, 2019

Lien : <https://doi.org/10.1016/j.apenergy.2019.01.029>